

Clasificación de tumores cerebrales en MRI mediante transfer learning con EfficientNet-B4

Ospina González, E.
Facultad de Ingeniería
Universidad de Antioquia
Medellin, Antioquia
estiven.ospinag@udea.edu.co

Peláez Acevedo, S.
Facultad de Ingeniería
Universidad de Antioquia
Medellin, Antioquia
sebastian.pelaez@udea.edu.co

Abstract—Brain tumors are abnormal cell growths in the brain or its surrounding structures whose early detection is critical to improving patient outcomes. The current diagnosis relies on the manual analysis of Magnetic Resonance Imaging (MRI) scans by specialized radiologists, a process that is time-consuming, subjective, and costly. This work proposes the development of a deep learning system for the automatic classification of 2D brain MRI images into four categories: glioma, meningioma, pituitary tumor and no-tumor. The system is trained and evaluated on a balanced public dataset of 7,200 grayscale images (5,600 training, 1,600 testing). Beyond class prediction, the system incorporates uncertainty quantification through Monte Carlo Dropout to provide clinically meaningful confidence estimates for each prediction. Two architectural approaches are compared: a custom convolutional neural network trained from scratch serving as a baseline, and a transfer learning strategy using distinct an ImageNet-pre-trained backbone (EfficientNetB4). Model performance is assessed using recall, F1-score macro, and Expected Calibration Error, with recall prioritized due to the high cost of missed tumor diagnoses. The comparative analysis aims to characterize the trade-offs between training from scratch and transfer learning in a medical imaging context.

Index Terms—brain tumor classification, MRI, deep learning, convolutional neural network, transfer learning, uncertainty quantification, Monte Carlo Dropout, medical image analysis.

I. INTRODUCCIÓN

Los tumores cerebrales son crecimientos anormales de células en el cerebro o en sus estructuras adyacentes. Su diagnóstico temprano mediante imágenes de Resonancia Magnética (MRI) es fundamental para orientar el tratamiento y mejorar el pronóstico del paciente. La RM produce múltiples cortes 2D que deben ser analizados por radiólogos especializados. Este proceso manual presenta tres limitaciones críticas:

- **Lento:** Consume un tiempo significativo de personal médico altamente especializado.
- **Subjetivo:** La interpretación puede variar entre diferentes especialistas.
- **Costoso:** Requiere acceso continuo a radiólogos con formación específica en neuroimagen.

La automatización de esta tarea mediante aprendizaje profundo permite escalar el diagnóstico, reducir la variabilidad inter-observador y apoyar la toma de decisiones clínicas en entornos con recursos limitados.

II. DESCRIPCIÓN DEL PROBLEMA

A. Contexto del problema

Los tumores cerebrales representan una de las condiciones neurológicas más críticas, donde el diagnóstico temprano y preciso puede marcar la diferencia entre un tratamiento exitoso y consecuencias irreversibles. Actualmente, su detección depende del análisis manual de imágenes de Resonancia Magnética (MRI) por parte de radiólogos especializados, un proceso lento, costoso y susceptible a variabilidad inter-observador.

Este proyecto propone desarrollar un sistema de clasificación automática de imágenes MRI cerebrales en cuatro categorías, glioma, meningioma, tumor pituitario e imagen normal, usando aprendizaje profundo. Se compararán tres enfoques arquitectónicos: una CNN diseñada desde cero como línea de referencia, y una estrategia de transfer learning con backbone preentrenado en ImageNet (EfficientNetB4).

El dataset utilizado es público, con 7.200 imágenes balanceadas entre las cuatro clases, lo que permite una evaluación rigurosa con métricas como F1-score macro y recall por clase, priorizando este último dado el alto costo clínico de un falso negativo.

B. Composición de la base de datos

Para el desarrollo de este proyecto se utiliza el *Brain Tumor MRI Dataset* [1], un conjunto de datos público disponible en Kaggle que contiene imágenes de resonancia magnética cerebral (MRI) clasificadas en cuatro categorías: *glioma*, *meningioma*, *tumor pituitario* y *sin tumor*. Estas categorías representan los tres tipos de tumores cerebrales más comunes en estudios de neuroimagen, además de imágenes correspondientes a pacientes sin evidencia de tumor.

Las imágenes se encuentran en escala de grises (modo de color *L*) y almacenadas en formato JPEG o PNG. Cada imagen corresponde a un corte bidimensional de resonancia magnética cerebral, con dimensiones típicas de aproximadamente 512×512 píxeles, tal como se muestra en la Fig 1.

El conjunto de datos contiene un total de 7.200 imágenes, ocupando aproximadamente 0,16 GB de almacenamiento.

La partición de entrenamiento está compuesta por 5.600 imágenes, distribuidas de manera uniforme entre las cuatro clases (Fig 2).




Fig. 1. Muestra de base de datos




Fig. 2. Distribución de clases en el conjunto de entrenamiento

Por su parte, la partición de prueba incluye 1.600 imágenes, con 400 imágenes por clase (Fig 3).




Fig. 3. Distribución de clases en el conjunto de prueba

El análisis de la distribución confirma que el dataset está perfectamente balanceado tanto en entrenamiento como en prueba, con exactamente 1.400 y 400 imágenes por clase respectivamente. Esta uniformidad elimina el riesgo de sesgo hacia clases mayoritarias durante el entrenamiento y permite evaluar el desempeño del modelo mediante métricas estándar como F1-score macro sin necesidad de técnicas adicionales de balanceo. A continuación se describe la naturaleza clínica de

cada categoría y sus características visuales en imágenes de RM.

C. Descripción clínica de las clases

Cada clase corresponde a un diagnóstico clínico diferente, con características visuales propias en las imágenes rm que el modelo debe aprender a discriminar. Las clases se encuentran descritas en la Tabla I.

TABLE I
DESCRIPCIÓN CLÍNICA POR CLASE

Clase	Descripción y características MRI
Glioma	<i>Clínica:</i> Tumor glial del SNC, bajo o alto grado. <i>MRI:</i> Masa heterogénea, bordes irregulares, edema perilesional.
Meningioma	<i>Clínica:</i> Tumor de meninges, benigno, crecimiento lento. <i>MRI:</i> Masa delimitada, homogénea, adherida a duramadre.
Pituitary	<i>Clínica:</i> Adenoma hipofisario, generalmente benigno. <i>MRI:</i> Masa selar/supraselar, señal homogénea.
No-tumor	<i>Clínica:</i> Imagen sin evidencia tumoral. Clase negativa. <i>MRI:</i> Anatomía normal, sin masas ni alteraciones.

D. Análisis de integridad y características del dataset

Se realizó una validación exhaustiva de la integridad del dataset verificando tres aspectos críticos:

- **Imágenes corruptas:** 0 imágenes corruptas o ilegibles detectadas en Training ni en Testing. El dataset está completamente íntegro.
- **Duplicados:** Se detectaron 20 grupos de imágenes duplicadas (mismo hash MD5) en el conjunto de Testing, todos dentro de la clase glioma.
- **Data leakage:** No se encontraron imágenes compartidas entre Training y Testing. Las particiones son estrictamente independientes.

La Figura 4 muestra la distribución de intensidad media por imagen para cada clase. Se observa que *glioma* presenta la menor intensidad media ($\mu = 40,5$, $\sigma = 17,3$), consistente con la presencia de zonas de necrosis y edema que reducen la señal en RM. En contraste, *notumor* exhibe la mayor intensidad media ($\mu = 60,4$, $\sigma = 21,8$), reflejo de un parénquima cerebral homogéneo sin alteraciones patológicas. Las clases *meningioma* y *pituitary* presentan valores intermedios similares ($\mu \approx 49$), aunque con distribuciones diferentes: *pituitary* muestra una distribución notablemente más compacta ($\sigma = 8,2$), indicativa de la morfología uniforme y localizada de este tipo de tumor. Estas diferencias, si bien sutiles a nivel estadístico global, justifican el uso de representaciones profundas capaces de capturar patrones espaciales locales.




Fig. 4. Distribución de intensidad media por imagen para cada clase del dataset.

III. FASES DEL PROYECTO

El desarrollo del proyecto se estructura en cinco fases secuenciales, donde cada una constituye un prerrequisito para la siguiente.

A. Fase 1: Exploración y análisis del dataset

Esta fase comprende el análisis exploratorio completo del conjunto de datos con el objetivo de caracterizarlo antes de cualquier decisión de modelado. Se verifica la estructura de directorios, el balance entre clases, las dimensiones de las imágenes y la integridad del dataset mediante detección de archivos corruptos, duplicados y posible *data leakage* entre particiones. Adicionalmente, se realiza un análisis estadístico a nivel de píxel, incluyendo histogramas de intensidad y medidas descriptivas (media, desviación estándar, mínimo y máximo) por clase, con el fin de identificar patrones visuales diferenciadores entre los distintos tipos de tumor y la clase sin tumor.

B. Fase 2: Preprocesamiento y construcción del pipeline

A partir de los hallazgos de la fase anterior, se diseña e implementa el pipeline de preprocesamiento adaptado a los requerimientos del modelo seleccionado. Esto incluye la definición de la resolución de entrada, el esquema de normalización y la repartición estratificada de los datos en conjuntos de entrenamiento, validación y prueba. El pipeline se construye sobre `tf.data` para garantizar eficiencia en la carga y procesamiento durante el entrenamiento.

C. Fase 3: Entrenamiento con transfer learning (EfficientNet-B4)

Esta fase desarrolla la arquitectura principal del proyecto. Se emplea EfficientNet-B4 preentrenada en ImageNet como backbone, sobre la cual se incorpora una cabeza de clasificación personalizada. El entrenamiento sigue una estrategia progresiva en dos subfases: en la primera, el backbone permanece completamente congelado y se optimizan únicamente los parámetros de la cabeza; en la segunda, se descongelan las capas superiores del backbone y se realiza *fine-tuning* con una

tasa de aprendizaje reducida para adaptar las representaciones aprendidas al dominio médico.

D. Fase 4: Entrenamiento de CNN desde cero (línea base)

Con el fin de cuantificar el aporte real de la transferencia de aprendizaje, se diseña e implementa una red neuronal convolucional entrenada completamente desde cero sobre el mismo conjunto de datos y con el mismo esquema de evaluación. Esta arquitectura sirve como línea de referencia (*baseline*) para la comparación directa contra el modelo de la Fase 3, permitiendo analizar las diferencias en velocidad de convergencia, rendimiento final y requerimientos computacionales entre ambos enfoques.

E. Fase 5: Comparación, análisis y conclusiones

La fase final integra los resultados de las fases anteriores en un análisis comparativo sistemático. Se evalúan ambas arquitecturas sobre el mismo conjunto de prueba usando las métricas definidas: recall por clase y F1-score macro. Se discuten las ventajas y desventajas de cada enfoque en el contexto del problema clínico, destacando el impacto de los falsos negativos por clase. Finalmente, se presentan las conclusiones del proyecto y se proponen líneas de trabajo futuro, incluyendo la implementación de estimación de confianza mediante Dropout para dotar al sistema de valor diagnóstico real.

IV. ESTRUCTURA DEL PROYECTO

A. Notebook 01 -Exploración de datos.ipynb

Este cuaderno corresponde a la fase de exploración inicial del conjunto de datos. Se verifica la estructura del dataset, el número de imágenes por partición, las dimensiones de las imágenes (512×512 píxeles), el balance entre clases y la ausencia de archivos corruptos o inconsistentes. Adicionalmente, se realiza un análisis a nivel de píxel mediante histogramas de intensidad y estadísticas descriptivas (media y desviación estándar) para cada categoría, con el fin de identificar patrones visuales diferenciadores entre los distintos tipos de tumor y la clase sin tumor.

B. Notebook 02 -Preprocesado.ipynb

En esta etapa se diseña e implementa el pipeline de preprocesamiento de datos. Se selecciona una resolución de entrada de 380×380 píxeles, correspondiente al tamaño estándar utilizado por EfficientNet-B4. Asimismo, se realiza una partición estratificada de los datos en conjuntos de entrenamiento, validación y prueba con proporciones de 70%, 15% y 15%, respectivamente. Finalmente, se implementan técnicas de aumento de datos adecuadas para imágenes médicas y se verifica la correcta normalización de los valores de intensidad antes del entrenamiento de los modelos.

C. Notebook 03 -Preprocesado.ipynb

Este cuaderno es en donde se hace el entrenamiento de línea base, se utiliza la API secuencial de Keras, y se construye una arquitectura en donde se utilizan varios pasos de Convolucion, Pooling y Dropout, esto para que la conexión a FFN no explote en la cantidad de parametros entrenables. La arquitectura queda con aproximadamente 29 millones de parametros entrenables. Se hace un entrenamiento utilizando los callbacks de Early Stopping, Reduce Learning Rate on Plateau y Model Checkpoint al igual que en la arquitectura construida con transfer learning.

D. Notebook 04 - Arquitectura EfficientNetB4 Transfer Learning.ipynb

Este cuaderno desarrolla la arquitectura principal basada en transferencia de aprendizaje utilizando EfficientNet-B4 preentrenada sobre ImageNet. Inicialmente se congelan las capas del backbone y se incorpora una cabeza de clasificación personalizada compuesta por capas densas y mecanismos de regularización mediante Dropout. El entrenamiento se realiza en dos fases. En la primera, únicamente se entrenan las capas de clasificación durante varias épocas mientras se monitorea el desempeño mediante callbacks como Early Stopping, Reduce Learning Rate on Plateau y Model Checkpoint. Posteriormente, se lleva a cabo un proceso de fine-tuning descongelando las capas superiores del backbone y utilizando una tasa de aprendizaje reducida para refinar las representaciones aprendidas. Adicionalmente, se implementa una red neuronal convolucional diseñada desde cero como línea base, permitiendo comparar de forma directa el desempeño de una arquitectura entrenada completamente desde cero frente a una estrategia de transferencia de aprendizaje.

V. PREPROCESAMIENTO DE IMÁGENES

El pipeline de preprocesamiento fue diseñado para satisfacer los requisitos de entrada de EfficientNet-B4 y garantizar la compatibilidad con los pesos preentrenados en ImageNet. La Fig 5 resume el flujo completo aplicado a cada imagen.




Fig. 5. Diagrama de preprocesamiento de imágenes.

A. Redimensionamiento y conversión de canales

Las imágenes originales del dataset presentan dimensiones variables, con un predominio de 512×512 píxeles en escala de grises (modo *L*). Dado que EfficientNet-B4 requiere una entrada de $380 \times 380 \times 3$, se aplican dos transformaciones secuenciales. Primero, cada imagen es redimensionada a 380×380 píxeles mediante interpolación LANCZOS, seleccionada por su calidad superior en operaciones de downscaling. Segundo, el canal gris único es replicado tres veces para construir una imagen RGB, dado que el backbone espera tres canales de entrada. Esta estrategia preserva la información de intensidad original sin introducir información espuria.

B. Normalización

Los valores de intensidad son normalizados mediante la función `preprocess_input` de EfficientNet, que aplica la media y desviación estándar de ImageNet ($\mu = [0,485, 0,456, 0,406]$, $\sigma = [0,229, 0,224, 0,225]$) produciendo valores en el rango $[-1, 1]$. Este esquema de normalización es el recomendado para modelos preentrenados en ImageNet y es condición necesaria para que las activaciones del backbone operen en el régimen para el que fueron optimizadas [2].

C. Partición estratificada de los datos

El dataset original de Kaggle contempla únicamente una partición de entrenamiento (5.600 imágenes) y una de prueba (1.600 imágenes). Con el fin de disponer de un conjunto de validación independiente para monitorear el entrenamiento, se realizó una repartición estratificada del conjunto de entrenamiento original en proporciones 70%, 15% y 15%, usando semilla aleatoria 42 para reproducibilidad. Los resultados se detallan en la Tabla II.

TABLE II
DISTRIBUCIÓN DE IMÁGENES TRAS LA REPARTICIÓN ESTRATIFICADA

Partición	Imágenes	Batches (bs=32)
Entrenamiento (70%)	3.916	122
Validación (15%)	840	26
Prueba (15%)	844	26
Total	5.600	—

La estratificación garantiza que la proporción de cada clase se mantenga constante en las tres particiones (aproximadamente 979, 210 y 211 imágenes por clase en entrenamiento, validación y prueba respectivamente).

D. Aumento de datos

Se implementó un esquema de aumento de datos conservador, diseñado específicamente para respetar la validez diagnóstica de las imágenes de RM. Las transformaciones aplicadas exclusivamente durante el entrenamiento son:

- **Rotación aleatoria** de hasta $\pm 10^\circ$.
- **Zoom aleatorio** en el rango $[0,9, 1,1]$.
- **Desplazamiento espacial** de hasta $\pm 5\%$ en ambos ejes.

Se descartaron explícitamente transformaciones de brillo y contraste, volteos horizontales y deformaciones elásticas, dado

que estas operaciones alteran las intensidades de señal o la orientación anatómica, que constituyen información diagnóstica relevante en neuroimagen.

E. Construcción del pipeline con *tf.data*

Los datasets fueron construidos con la API *tf.data* de TensorFlow, con las siguientes optimizaciones:

- **Carga diferida (*lazy loading*)** para minimizar el uso de memoria RAM.
- **Preprocesamiento y aumento de datos *on-the-fly*** con paralelización automática mediante *AUTOTUNE*.
- ***Prefetching*** para solapar la preparación del siguiente batch con el cómputo del paso de entrenamiento actual. El aumento de datos se aplica únicamente al dataset de entrenamiento; los datasets de validación y prueba reciben únicamente el redimensionamiento y la normalización.

En la Figura 6 se puede observar el resultado del batch preprocesado.




Fig. 6. Visualización del batch preprocesado.

VI. DESCRIPCIÓN DE LA SOLUCIÓN

A. Arquitectura

La arquitectura propuesta se basa en *transfer learning* progresivo sobre EfficientNet-B4 [2], preentrenada en ImageNet. El backbone cuenta con 476 capas y 17.673.823 parámetros, y produce un vector de 1.792 características mediante *Global Average Pooling*.

El entrenamiento sigue una estrategia de congelamiento progresivo en dos fases. En la Fase 1, todas las capas del backbone son congeladas y se entrena únicamente la cabeza de clasificación personalizada, compuesta por: una capa densa de 512 unidades con activación ReLU, Dropout con tasa 0,5, una segunda capa densa de 256 unidades con activación ReLU, Dropout con tasa 0,5, y una capa de salida de 4 unidades con activación Softmax. Esta configuración suma 1.050.372 parámetros entrenables, equivalente al 5,6% del total del modelo. En la Fase 2, se descongelan las capas superiores del backbone y se realiza *fine-tuning* con una tasa de aprendizaje reducida para adaptar las representaciones al dominio médico.

El modelo fue compilado con el optimizador Adam ($\text{lr} = 10^{-3}$, $\beta_1 = 0,9$, $\beta_2 = 0,999$, $\text{clipnorm} = 1,0$) y función de pérdida *categorical crossentropy*. Durante el entrenamiento se

emplearon tres *callbacks*: *EarlyStopping* con *patience* = 5 monitoreando *val_loss*, *ReduceLROnPlateau* con factor 0,5 y *patience* = 2, y *ModelCheckpoint* para preservar los pesos con mejor pérdida de validación (Fig 7).




Fig. 7. Diagrama de arquitectura del modelo

VII. ITERACIONES

El desarrollo del modelo siguió un proceso iterativo estructurado en fases sucesivas, donde cada etapa informó las decisiones de la siguiente.

A. Iteración 1: Exploración y validación del dataset

La primera iteración consistió en un análisis exploratorio completo del conjunto de datos. Se verificó la estructura de directorios, el balance entre clases, las dimensiones de las imágenes y la ausencia de archivos corruptos. Se realizó además un análisis a nivel de píxel mediante histogramas de intensidad por clase, que reveló diferencias sutiles en las distribuciones de señal entre tipos de tumor: la clase *notumor* presenta la mayor intensidad media (60,4), mientras que *glioma* muestra la más baja (40,5), consistente con la presencia de zonas de necrosis y edema. La validación de integridad detectó 0 imágenes corruptas y confirmó la ausencia de *data leakage* entre particiones. Se identificaron 20 grupos de imágenes duplicadas por hash MD5 en el conjunto de prueba, todos dentro de la clase *glioma*, hallazgo documentado pero de impacto menor dado que no afecta el entrenamiento.

B. Iteración 2: Diseño del pipeline de preprocesamiento

En esta fase se tomaron las decisiones clave del pipeline: resolución de entrada 380×380 píxeles, normalización con *preprocess_input* de EfficientNet, y conversión de escala de grises a RGB por replicación de canal. Se implementó la repartición estratificada 70/15/15, obteniendo 3.916, 840 y 844 imágenes para entrenamiento, validación y prueba respectivamente. Se definió el esquema de aumento de datos conservador (rotación $\pm 10^\circ$, zoom $\pm 10\%$, desplazamiento $\pm 5\%$) y se construyeron los datasets con *tf.data* con carga diferida y *prefetch*. Se verificó que los batches resultantes tuvieran la forma esperada (32, 380, 380, 3) y que los valores de normalización fueran correctos.

C. Iteración 3: Construcción y validación de la arquitectura

Se cargó EfficientNet-B4 preentrenada en ImageNet con `include_top=False` y `pooling='avg'`, y se construyó la cabeza de clasificación personalizada. Se congelaron las 476 capas del backbone, dejando únicamente 1.050.372 parámetros entrenables. Se realizó un *forward pass* de validación con un batch de 16 imágenes para confirmar que el flujo de datos era correcto y que la salida tenía la forma esperada (16, 4) antes de iniciar el entrenamiento.

D. Iteración 4: Entrenamiento de la cabeza (Fase 1)

Con el backbone congelado, se entrenó únicamente la cabeza personalizada durante 5 épocas con tasa de aprendizaje 10^{-3} y tamaño de batch de 16. Al finalizar, el modelo alcanzó una pérdida de validación de 0,2118 y una exactitud de validación del 93,10%, superando a la exactitud de entrenamiento (90,96%), lo que indica una buena capacidad de generalización sin sobreajuste en esta fase. La evaluación sobre el conjunto de prueba reportó una exactitud global del 91,35% y un F1-score macro de 0,9119. El desempeño fue diferenciado por clase: *notumor* obtuvo el mejor resultado (F1 = 0,963, recall = 99,1%), mientras que *meningioma* fue la clase más difícil (F1 = 0,829, recall = 79,1%), identificándose como el principal objetivo de mejora en iteraciones siguientes. Estos resultados se pueden observar en la Tabla III.

TABLE III

CONFIGURACIÓN Y RESULTADOS DE LA FASE DE ENTRENAMIENTO DE LA CABEZA PERSONALIZADA

Parámetro / Métrica	Valor
<i>Configuración de entrenamiento</i>	
Estado del backbone	Congelado
Épocas	5
Tasa de aprendizaje	10^{-3}
Tamaño de batch	16
<i>Resultados de validación</i>	
Pérdida de validación	0,2118
Exactitud de validación	93,10%
Exactitud de entrenamiento	90,96%
<i>Resultados sobre conjunto de prueba</i>	
Exactitud global	91,35%
F1-score macro	0,9119
<i>Desempeño por clase</i>	
<i>notumor</i> — F1	0,963
<i>notumor</i> — Recall	99,1%
<i>meningioma</i> — F1	0,829
<i>meningioma</i> — Recall	79,1%

E. Iteración 5: Entrenamiento de la arquitectura base

La arquitectura base fue entrenada durante 5 épocas con tasa de aprendizaje 10^{-3} y tamaño de batch de 16, esto para estandarizar los hiperparametros elegidos en el entrenamiento de la arquitectura de transfer learning. Al finalizar, el modelo alcanzó una pérdida de validación de 0.2763 y una exactitud de validación del 91,31%. La evaluación sobre el conjunto de prueba reportó una exactitud global del 89.57% y un F1-score macro de 0.8953. El desempeño fue diferenciado por clase: *notumor* obtuvo el mejor resultado (F1 = 0,945, recall = 95,2%), mientras que *meningioma* fue la clase más difícil




Fig. 8. Visualización historial entrenamiento - EfficientNet-B4.

(F1 = 0,811, recall = 81,1%). Estos resultados se pueden observar en la Tabla IV.

TABLE IV

CONFIGURACIÓN Y RESULTADOS DE LA FASE DE ENTRENAMIENTO DE LA ARQUITECTURA BASE

Parámetro / Métrica	Valor
<i>Configuración de entrenamiento</i>	
Épocas	5
Tasa de aprendizaje	10^{-3}
Tamaño de batch	16
<i>Resultados de validación</i>	
Pérdida de validación	0,2763
Exactitud de validación	91,31%
Exactitud de entrenamiento	92,47%
<i>Resultados sobre conjunto de prueba</i>	
Exactitud global	89,57%
F1-score macro	0,8953
<i>Desempeño por clase</i>	
<i>notumor</i> — F1	0,945
<i>notumor</i> — Recall	95,2%
<i>meningioma</i> — F1	0,811
<i>meningioma</i> — Recall	81,1%

F. Iteraciones planificadas

Como continuación del proceso, se tienen previstas dos iteraciones adicionales. La primera corresponde a la Fase 2 de fine-tuning, en la que se descongelarán las capas superiores del backbone y se reentrenará el modelo completo con tasa de aprendizaje reducida (10^{-5}), buscando adaptar las representaciones de ImageNet al dominio médico y mejorar el recall en *meningioma*.

VIII. CONCLUSIONES

Al analizar la relación costo-beneficio, la elección de EfficientNet-B4 con Transfer Learning sobre una arquitectura propia resulta superior por tres pilares fundamentales: rendimiento técnico, eficiencia operativa y estabilidad del modelo.

A. Superioridad en Métricas de Clasificación

Aunque ambas arquitecturas muestran resultados sólidos, EfficientNet-B4 supera a la arquitectura propia en prácticamente todos los indicadores clave:

- **Precisión General (Accuracy):** EfficientNet alcanza un 91,3% frente al 89,5% de la propia. En contextos médicos (como la detección de tumores), un margen del 2% es crítico para la seguridad del paciente.
- **Capacidad de Detección (Recall):** EfficientNet tiene un desempeño sobresaliente en la clase notumor (99%) y pituitary (97%). Esto significa que el modelo es extremadamente confiable para descartar falsos negativos, asegurando que los casos sanos se identifiquen correctamente y los tumores no pasen desapercibidos.
- **Robustez (F1-Score):** El promedio ponderado del F1-Score es mayor en EfficientNet (0.9119 vs 0.8953), lo que indica un mejor equilibrio entre precisión y sensibilidad en todas las clases.

B. Eficiencia de Recursos (El "Costo" del Entrenamiento)

Entrenar una arquitectura desde cero tiene costos ocultos que el Transfer Learning elimina:

- **Tiempo de Cómputo:** EfficientNet-B4 ya "sabe" extraer características visuales complejas (bordes, texturas, formas) gracias a su pre-entrenamiento en ImageNet. Al hacer transfer learning, solo ajustas las capas finales, lo que requiere muchas menos épocas de entrenamiento y menor consumo de GPU para dar muy buenos resultados, aplicables al contexto clínico.
- **Curva de Aprendizaje:** Una arquitectura propia suele requerir un proceso exhaustivo de prueba y error (ajuste de hiperparámetros, número de filtros, capas de dropout). EfficientNet utiliza un escalado compuesto (*compound scaling*) que optimiza matemáticamente la profundidad, anchura y resolución, ahorrándote horas de ingeniería manual.

En conclusion, utilizar EfficientNet-B4 no solo es "más barato" en términos de tiempo y recursos de cómputo, sino que entrega un producto final más preciso y confiable. La arquitectura propia, aunque competitiva, no logra alcanzar el nivel de generalización que ofrece el escalado optimizado de EfficientNet, lo que la hace menos eficiente en la relación inversión/resultado, esto comparandolas con las 5 epocas de entrenamiento y los hiperparametros elegidos.

REFERENCES

- [1] M. Nickparvar, "Brain Tumor MRI Dataset," Kaggle, 2026. Available: <https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>
- [2] M. Tan and Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," *Proc. Int. Conf. Mach. Learn. (ICML)*, 2019.